

Classificação de Imagens com Redes Convolucionais: Cães vs. Gatos *

Image Classification with Convolutional Neural Networks: Dogs vs. Cats

Luan Barbosa Rosa Carrieros¹

8 de junho de 2025

Resumo

Este trabalho detalha o desenvolvimento e a avaliação de uma Rede Neural Convolucional (CNN) para a classificação binária de imagens da base de dados “Dogs vs. Cats” do Kaggle. São descritas as etapas de pré-processamento, incluindo a divisão dos conjuntos de dados e o aumento de dados (data augmentation), seguidas pela construção, treinamento e avaliação do modelo. O modelo treinado alcançou uma acurácia de 86% no conjunto de teste, e sua capacidade de generalização foi validada com sucesso em imagens externas. Os resultados demonstram a eficácia das CNNs para tarefas de visão computacional.

Palavras-chave: Inteligência Artificial. CNN. Classificação de Imagens. Visão Computacional. Gatos. Cães.

*Trabalho apresentado à disciplina de Inteligência Artificial do Instituto de Ciências Exatas e Informáticas da Pontifícia Universidade Católica de Minas Gerais, sob orientação da Profª. Cristiane Neri Nobre.

¹Aluno do Curso de Ciência da Computação (Matrícula: 816676, Cód. Pessoa: 1415259), Brasil. E-mail: luan.rosa@sga.pucminas.br.

1. INTRODUÇÃO

As Redes Neurais Convolucionais (CNNs) representam o estado da arte em diversas tarefas de visão computacional, graças à sua notável capacidade de aprender hierarquias de características diretamente das imagens. Este trabalho aplica essa técnica para resolver o clássico problema de classificação binária entre imagens de gatos e cachorros. O objetivo é construir um pipeline completo, desde o tratamento dos dados até a avaliação final, utilizando a popular base de dados “Dogs vs. Cats” como referência.

2. METODOLOGIA E PREPARAÇÃO DOS DADOS

O sucesso de um modelo de aprendizado profundo depende fundamentalmente da qualidade e da preparação dos dados. As seguintes etapas foram executadas:

- **Fonte de Dados:** Foi utilizada a base de dados “Dogs vs. Cats” da plataforma Kaggle.
- **Divisão dos Conjuntos:** A base de dados foi segmentada em três conjuntos: 70% para treino (17.500 imagens), 15% para validação (3.750 imagens) e 15% para teste (3.750 imagens).
- **Pré-processamento de Imagens:** Todas as imagens foram padronizadas para 150x150 pixels e seus valores de pixel normalizados para o intervalo [0, 1]. No conjunto de treino, foi aplicada a técnica de *data augmentation* (rotação, zoom, inversão) para aumentar a variedade dos dados e reduzir o overfitting.

3. ARQUITETURA E TREINAMENTO DA CNN

O modelo foi construído com a API Sequencial do Keras, composto por três blocos convolucionais (‘Conv2D’ + ‘MaxPooling2D’), uma camada de achatamento (‘Flatten’) e duas camadas densas (‘Dense’). A camada de saída utiliza a função de ativação ‘sigmoid’, adequada para classificação binária. O modelo foi compilado com o otimizador ‘Adam’ e a função de perda ‘binary_crossentropy’. O treinamento foi realizado a longo de 15 épocas.

4. RESULTADOS E ANÁLISE

4.1. Análise do Treinamento

A performance durante o treinamento foi monitorada através das métricas de acurácia e perda, conforme as Figuras 1 e 2. O comportamento das curvas de treino e validação indica um aprendizado estável e sem overfitting significativo, validando a eficácia das técnicas de regularização aplicadas.




Figura 1 – Gráfico da Acurácia de Treino e Validação por Época.

4.2. Avaliação Final do Modelo

No conjunto de teste, o modelo obteve uma performance final robusta, cujas métricas estão resumidas na Tabela 1.

Tabela 1 – Métricas de Desempenho no Conjunto de Teste.

Classe	Precisão	Recall	F1-Score
Gatos (cats)	0.89	0.82	0.86
Cães (dogs)	0.84	0.90	0.87
Acurácia Total	86%		




Figura 2 – Gráfico da Perda de Treino e Validação por Época.

5. TESTE COM IMAGENS EXTERNAS

Para validar a aplicação prática do modelo, foram realizados testes com imagens externas. O modelo foi capaz de classificar corretamente as novas imagens, como demonstrado na Figura 3.



Figura 3 – Classificação de imagens externas: gato (esquerda) e cachorro (direita).

6. CONCLUSÃO

O modelo de CNN desenvolvido neste trabalho provou ser eficaz para a tarefa proposta, alcançando 86% de acurácia em um conjunto de teste inédito. O pipeline bem estruturado, desde o pré-processamento dos dados até a avaliação final, foi crucial para o sucesso do projeto. O treinamento estável, sem overfitting, e a correta classificação de imagens externas confirmam a robustez do modelo.

Código-fonte disponível em: <<https://github.com/LuanCarrieiros/IA/blob/main/Lista12/lista12.ipynb>>